

哈尔滨工业大学

硕士学位论文中期报告

题 目：基于深度强化学习的多目标无人机路径导航
研究
(学位论文)

学 院 （部）	计算学部
学科/专业学位类别	计算机技术
导 师	李治军
研 究 生	王世豪
学 号	24S136052
中期报告日期	2026 年 6 月

研究生院制

目 录

1 学术研究或者实践工作进度情况	1
2 目前已完成的学术研究或者实践工作内容和取得的研究结果	1
2.1 两层系统总体设计	1
2.2 上层：基于指针网络的多目标 TSP 规划	2
2.2.1 指针网络 TSP 策略架构	2
2.2.2 实验：500 实例批量评测	3
2.3 下层：AirSim 环境上的 DRL 导航实验	6
2.3.1 SAC-DepthMaxPool 策略架构	7
2.3.2 实验：算法与感知对比	9
2.3.3 单点导航能力评测	10
2.4 上下层联合评测	11
2.5 阶段性小结	13
3 目前存在的或预期可能出现的问题	13
4 后期学术研究或者实践工作的进度安排	14

1 学术研究或者实践工作进度情况

本课题面向农业巡检、工业运维等多目标作业场景，采用“上层 TSP 序列规划 + 下层 AirSim 强化学习导航避障”的两层架构。上层将多目标点访问顺序抽象为 TSP，利用指针网络快速近似最优访问顺序；下层在 AirSim SimpleAvoid 场景中训练 SAC 等 DRL 策略，实现连续空间避障逐点飞行；上下层通过联合评测分析路径质量与任务成功率的协同关系。

研究路径分为两阶段。中期阶段的工作已基本完成：上层完成了无障碍 TSP 训练与 500 实例评测，下层完成了导航 benchmark 与单点能力验证，并完成了 100 组初步联合评测，同时搭建了从上层批量评测到联合评测的实验流水线。进入中期之后（论文主体阶段），将在 TSP 序列训练中引入障碍物惩罚，使上层规划与下层可飞性对齐，并将联合评测扩展至 500 组，系统检验路径质量与任务成功率之间的关系；同时，当前上层固定为 $n = 20$ 的 TSP20 设定，与实际多目标作业规模仍有差距，后续将逐步扩展至 50 点乃至更多目标点的训练与评测。

研究内容涵盖基于 Pointer Network 的 TSP20 指针网络训练与 500 实例评测，下层四种算法与感知配置对比（各 20 万训练步），100 组 Optimal 与 RL-Greedy 的初步联合评测，以及为障碍物惩罚 TSP、TSP 规模扩展与扩展联合评测预留的实验流水线。

已完成的工作可概括如下。上层 500 实例 TSP 评测中，RL-Greedy 平均 $L/L_{\text{opt}} = 1.006$ ，并已生成 ratio 曲线（图 4）及训练过程与单实例路径可视化（图 3）。下层算法对比中，SAC-DepthMaxPool 最终 rollout 成功率 94%（峰值 98%），TD3 为 75%，SAC-mlp 为 61%，PPO 尚未收敛（图 6）。联合评测以最优 SAC 为下层策略，在 100 组实例上得到 Optimal 67%、RL-Greedy 82% 的整链成功率（表 9），二者均明显低于单点 95.2%，说明连续逐点任务会显著拉低避障成功率。单点导航方面，最优 SAC 在训练分布下 500 次评测的成功率为 95.2%（表 8）。此外，下层算法对比实验已实现训练曲线与汇总数据的自动产出。

对照开题进度，上层 TSP、下层导航 benchmark 与初步联合评测均按期完成；障碍物惩罚 TSP 与扩展联合评测按研究路径安排在中期之后推进。联合评测采用经 10^5 步训练得到的最优 SAC（SAC-DepthMaxPool，SimpleAvoid 场景）作为下层固定策略，结果见表 9。

2 目前已完成的学术研究或者实践工作内容和取得的研究结果

2.1 两层系统总体设计

系统面向多目标巡检作业，分为上层序列规划与下层连续导航：上层输入 $N = 20$ 个二维目标点，用指针网络输出访问排列 π ；下层以 π 中各点为子目标，调用

SAC 在 AirSim 中依次避障飞行。实验数据流为：上层批量生成评测实例 $\rightarrow$ 构建标准测试集 $\rightarrow$ 上下层联合评测。中期之后将在上层 TSP 训练/解码中引入障碍物惩罚，使路径质量指标与下层任务成功率更好对齐。

图 1 从左至右展示三层信息流：多目标任务输入（航点集合 S 与含障环境）；中央为分层架构，上层 Pointer Network TSP 输出访问序列 π 及有序航点 $\pi(S)$ ，虚线框表示障碍物感知代价对序列规划的扩展输入；下层 SAC 策略在 AirSim 静态障碍环境中按子目标链逐段避障飞行；右侧为端到端执行轨迹。




图 1: 两层系统总体架构

2.2 上层：基于指针网络的多目标 TSP 规划

多目标几何路径建模为 TSP^[1]。上层采用 Bello 等人的 NCO 框架^[2] 与 Vinyals 等人的指针机制^[3]，实现基于 Actor-Critic REINFORCE 的指针网络训练与多种解码策略。中期 500 实例评测采用与 SimpleAvoid 同尺度的障碍地图采样 ($n = 20$)；对照实验可切换为单位正方形均匀采样 ($[0, 1]^2$)。

2.2.1 指针网络 TSP 策略架构

本小节考虑对称 TSP：给定 $n = 20$ 个二维城市坐标 $\mathbf{s}_i = (x_i, y_i)$ ，求访问排列 π 使闭合回路欧氏长度 $L(\pi)$ 最小。网络输入为 $(B, n, 2)$ 的 batch，不设单独 depot 节点。

编码端采用一维卷积层 $\text{Conv1d}(2 \rightarrow 128, k = 1)$ 将各城市嵌入 128 维，再经 $\text{LSTM}(128 \rightarrow 128)$ 编码为节点序列 $\mathbf{h}_1, \dots, \mathbf{h}_n$ （表 1）。解码端以 LSTM 末态 (h, c) 初始化 LSTM 单元，逐步解码 n 步：每步先用 Glimpse 注意力 ($w_{ref} \text{Conv1d} + w_q \text{Linear} + v \cdot \tanh$) 聚合未访问节点，再经指针层输出 logits = $C \cdot \tanh(\text{scores})$ ($C = 10$)，对已访问城市施加 mask；训练时按 Categorical 采样，推理 Greedy 时 argmax。推

理阶段 scores 除以温度 $T=2.0$ 。

Critic 基线与 Encoder 同构，采用 embed LSTM，接 3 步 Glimpse process block 与两层 FFN，输出标量 $b(s)$ 作为 REINFORCE 基线，用于降低梯度方差。训练目标方面，Actor 损失为 $\mathbb{E}[(L(\pi) - b(s)) \log p(\pi)]$ ，Critic 损失为 $\text{MSE}(b(s), L(\pi))$ ；采用 Adam 优化，TSP20 下 batch=128、lr= 10^{-3} 、每 5000 步衰减 0.96、共 100k 步，梯度裁剪 $\|\nabla\|_2 \leq 1.0$ 。如图 2 所示，城市坐标经 Actor 分支（Encoder-PointerDecoder）输出排列 π 与 $\log p(\pi)$ ，Critic 分支估计基线 $b(s)$ ，以回路长度 $L(\pi)$ 驱动 REINFORCE 更新；Decoder 以 $\langle g \rangle$ 为起点逐步 pointing 未访问节点，Visit Mask 保证 π 为有效排列^[2,3]。

推理解码提供三种策略：RL-Greedy 为逐步贪心解码，作为默认上层输出；RL-Sampling 进行 256 次随机采样并取最短回路（balanced 预设）；RL-AS 在预训练权重基础上进行 300 步实例级 Active Search，EMA 基线 $\alpha=0.99$ 。架构与训练/解码超参分别见表 1、表 2。




图 2: 指针网络 TSP 训练架构（Actor-Critic REINFORCE）

RL-Greedy 为默认上层解码输出，其规划序列将用于后续联合评测。

2.2.2 实验：500 实例批量评测

中期 500 实例评测在 obstacle_map 分布上进行，对各解码策略与 Christofides、2-opt、Held-Karp 最优等基线进行对比，汇总见表 3、表 4；训练过程与单实例可视化见图 3，相对最优比率曲线见图 4。


图 3 展示 REINFORCE 训练过程与单实例解码效果。图（a）为测试批平均回

表 1: 指针网络 TSP 编码—解码—基线结构


层级	模块	说明
输入	$(B, n, 2)$ 城市坐标	障碍地图或单位正方形采样
Encoder	Conv1d + LSTM	$2 \rightarrow 128 \rightarrow 128$, 节点嵌入
Decoder	LSTMCell + Glimpse + Pointer	mask 已访问; logits = $C \tanh(\cdot)$
Critic	Encoder + 3×Glimpse + FFN	标量基线 $b(s)$
目标	回路长度 $L(\pi)$	对称 TSP 闭合回路欧氏长度

表 2: 指针网络 TSP 训练与解码超参 (TSP20 / 中期评测)

参数	训练	500 实例评测
城市数 n	20	20
batch / embed / hidden	128 / 128 / 128	—
学习率 / 衰减	10^{-3} , 5000 步 $\times 0.96$	—
训练步数	10^5 (NCO: 2.5×10^5)	—
C / 温度 T	10 / 2.0	推理用 T
Critic process 步数	3	—
RL-Greedy	—	逐步贪心解码
RL-Sampling	—	256 次采样取最短
RL-AS	—	300 步, lr= 10^{-5} , $\alpha = 0.99$



(a) 训练平均回路长度曲线



(b) 单实例 RL-Greedy 规划路径

图 3: 指针网络 TSP 训练过程与单实例路径可视化 (obstacle_map, $n = 20$)

表 3: 上层 TSP 各方法平均回路长度（500 实例）

方法	均值	标准差	最小值	最大值
初始随机序	1337.77	142.59	991.69	1776.93
Christofides	421.27	33.20	343.81	550.73
2-opt	452.53	42.19	366.71	599.49
RL-Greedy	408.18	26.26	343.81	501.42
RL-Sampling	406.05	25.53	341.42	501.02
RL-AS	406.30	25.65	341.42	501.42
Optimal	405.65	25.27	341.42	501.02

表 4: 上层 TSP 相对最优比率及配对统计（500 实例）

方法 / 统计项	数值
RL-Greedy ratio 均值	1.006
RL-Sampling ratio 均值	1.001
RL-Greedy 达到最优	267/500
RL-Greedy 短于 Christofides	434/500




图 4: TSP 相对最优比率曲线（500 实例）

路长度随训练轮数的变化：0–750 轮由约 900–1050 快速降至 550 附近，750–7500 轮继续缓降至约 440–450，7500 轮后进入平台期并在 2 万轮附近稳定在 420–430，表明指针网络在 `obstacle_map` 分布上已习得有效的序列构造策略。曲线全程存在高频抖动，来自 REINFORCE 采样式梯度估计的固有方差，整体无发散或性能回退。该曲线与 500 实例评测中 RL-Greedy 均值 408.18 的量级一致；完整 10^5 步训练后，几何质量将进一步收敛至表 3 所示水平。图（b）为 `obstacle_map` 尺度下单组 20 城市实例的 RL-Greedy 闭合回路：红色折线依次连接各航点并回到起点，形成有效 Hamiltonian 环。多数相邻段遵循“就近连接”的局部几何直觉，左中部与右缘可见少量自交叉或折返，对应尚未达到 Held-Karp 最优的局部冗余，与全量评测均值 ratio 1.006、53.4% 实例达最优的统计相符。该访问序转换为逐点目标序列后，即作为下层 SAC 的子目标输入。

从绝对回路长度看，RL-Greedy 均值 408.18 已低于 Christofides (421.27) 与 2-opt (452.53)，并逼近 Held-Karp 最优 (405.65)；标准差 26.26 与最优解 25.27 同量级，说明学习得到的策略在 `obstacle_map` 实例上不仅均值较优，离散程度也与精确最优相当。相对最优比率方面，RL-Greedy 均值 $L/L_{\text{opt}} = 1.006$ ，中位数为 1.000，即半数实例已达最优；267/500 (53.4%) 与最优等长，434/500 (86.8%) 短于 Christofides，而 Christofides 仅 49/500 优于 RL-Greedy，表明在本文地图分布下经典近似算法并不占优。

图 4 的排序曲线呈现清晰分层：随机初始序（均值 ratio 3.31）与启发式（Christofides 1.04、2-opt 1.12）位于上方，RL 系列（Greedy/Sampling/RL-AS）紧贴最优曲线下方。就解码策略而言，256 次采样的 RL-Sampling 将均值 ratio 降至 1.001，446/500 达最优，相对 Greedy 的 267/500 有 179 例提升，但均值差距仅 0.005，说明 Greedy 已接近采样解码的收益上限；RL-AS (300 步) 与 Sampling 均值接近 (1.0015 vs 1.0010)，实例级微调带来的边际收益有限。上层指针网络在中期 TSP20 设定下已具备可用的序列规划能力；后续主要瓶颈不在几何 ratio，而在与下层可飞性的对齐，以及目标规模从 20 点向 50 点及以上扩展后的训练收敛与评测可行性。

2.3 下层：AirSim 环境上的 DRL 导航实验

参考 He 等人^[4]的 AirSim 深度强化学习导航框架与 Liu 等人的层次 DRL 导航^[5]，本人在 Gym 接口下封装 SimpleAvoid 多旋翼仿真环境，采用 SAC^[6]为主算法，奖励采用综合塑形函数。下层主策略为 SAC-DepthMaxPool（深度 MaxPool 编码器）：在 Stable-Baselines3 策略框架上挂载自定义 DepthMaxPool 特征提取器，按统一超参数配置进行训练。

2.3.1 SAC-DepthMaxPool 策略架构

环境接口采用深度图感知：AirSim 深度传感器输出经裁剪、缩放为 60×90 深度图（有效距离 15 m，近障碍高亮），与 2 维状态特征共同构成双通道观测 $\mathbf{o} \in \mathbb{R}^{60 \times 90 \times 2}$ 。状态特征嵌入第二通道首行，2D 导航下为归一化水平距离与相对偏航角；动作 $\mathbf{a} = (v_{xy}, \dot{\psi})$ ，分别为水平速度与偏航角速度（ $v_{xy} \in [0.5, 5]$ m/s, $\dot{\psi} \in [-30^\circ, 30^\circ]/s$ ）。动力学采用简化多旋翼模型（ $dt = 0.1$ s），奖励含距离塑形与障碍/姿态惩罚。

DepthMaxPool 对深度通道做 16×20 区域最大池化（无卷积）： 60×90 深度图降采样为 $3 \times 4 = 12$ 维区域最大深度；再从第二通道读取 2 维状态，拼接为 14 维向量供后续 MLP 使用（表 5）。DepthMaxPool 作为 Actor 与 Twin Critic 的共享特征提取器；Actor 经 MLP [64, 32, 16]（tanh）输出 Squashed Gaussian 分布，Critic 为双 Q 网络。Off-policy 训练采用经验回放（buffer 50000，batch 512），每 100 步采集后更新 100 次梯度；探索阶段附加 $\sigma = 0.15$ 高斯动作噪声。图 5 概括感知、DepthMaxPool 与 SAC 三层数据流：深度图经区域 MaxPool 压缩为 12 维障碍特征，与 2 维状态拼接后供 Actor/Critic 共享；算法对比实验中该配置 rollout 成功率 94%。细节见表 5、表 6。




图 5: SAC-DepthMaxPool 策略架构

相较 SAC-mlp（5 维手工向量特征），DepthMaxPool 保留完整深度图的空间结构，对比实验中最终成功率 94% vs 61%。本课题选定 SAC-DepthMaxPool 作为下层主策略及联合评测固定执行器。

表 5: SAC-DepthMaxPool 观测—特征—策略结构

层级	模块	说明
感知	AirSim 深度传感器	resize 60×90 , 映射 $[0, 15] \text{ m} \rightarrow [0, 255]$
观测	双通道 $(H, W, 2)$	通道 0: 深度; 通道 1 第 0 行: 状态
特征	DepthMaxPool	MaxPool $\rightarrow$ 12 维 + 状态 2 维 = 14 维
Actor	MLP[64, 32, 16]+Squash	输出 (v_{xy}, ψ)
Critic	Twin Q, 共享特征	Q_1, Q_2 : 特征与动作拼接后 MLP

表 6: SAC-DepthMaxPool 训练超参（对比实验）


参数	对比实验
训练步数	2×10^5
学习率 / γ	$10^{-3} / 0.99$
buffer / batch	50000 / 512
采集间隔 / 梯度更新	100 步 / 100 次
网络结构	[64, 32, 16]
动作噪声 σ	0.15
accept / crash 半径	2 m / 2 m

2.3.2 实验：算法与感知对比


对比 SAC、TD3、PPO 及 SAC-mlp（向量感知消融）四组配置，汇总见表 7，训练过程 rollout 指标曲线见图 6。

表 7: 下层导航算法对比（SimpleAvoid，各 20 万步，rollout 指标）


配置	算法	最终成功率	峰值成功率	最终平均奖励	撞毁率	平均步数
SAC-DepthMaxPool	SAC	94%	98%	+9.55	6%	201
TD3-DepthMaxPool	TD3	75%	84%	+3.72	24%	164
SAC-mlp	SAC	61%	74%	-13.95	37%	227
PPO-DepthMaxPool	PPO	0%	0%	-244.24	5%	392




(a) 成功率



(b) 碰撞率



(c) 平均回合奖励



(d) 平均回合步数

图 6: 四种配置训练 rollout 指标曲线

四组 rollout 曲线在四项指标上形成稳定排序，SAC-DepthMaxPool 综合最优，且各指标之间逻辑自治。

就成功率与收敛速度而言，SAC 曲线在中期约 4.4 万步首次超过 75%，7.2 万步超过 90%，20 万步终值 94%（峰值 98%）；TD3 直至 14.7 万步才达到 75%，全程未突破 90%。在共享 DepthMaxPool 感知的前提下，SAC 比 TD3 提前约 10 万步进入可用区间，终值成功率高出 19 个百分点，说明 off-policy 双 Q 结构与熵正则

在本环境中更利于样本效率。SAC-mlp 终值 61%（峰值 74%），全程未达 75%，与 SAC-DepthMaxPool 形成 33 个百分点的感知消融差距，表明 12 维区域深度特征对保留障碍空间结构至关重要。PPO 成功率恒为 0%，策略未习得有效到达行为。

碰撞率与成功率呈显著负相关：SAC 终值 6%，TD3 24%，SAC-mlp 37%。TD3 成功率低于 SAC 但碰撞率却为其 4 倍，说明 TD3 在部分回合中以撞障或失败终止，而非稳定到达。PPO 碰撞率 5% 看似较低，但结合 0% 成功率与 392 步的平均回合长度，更可能以超时或边界条件结束回合，而非安全到达。

平均奖励方面，SAC 在约 4.9 万步首次转正，终值 +9.55（训练期峰值 +13.40）；TD3 约 13.8 万步才转正，终值 +3.72。SAC-mlp 与 PPO 终值分别为 -13.95 与 -244.24，全训练期均值亦为负（-30.5 与 -226.8），反映策略长期受距离塑形与障碍惩罚压制。SAC 的奖励曲线与成功率曲线同步上升，可作为训练监控的有效代理指标。

平均步数方面，SAC 终值约 201 步/回合，TD3 约 164 步。TD3 步数更短但成功率更低，说明其回合往往更早以失败结束；PPO 约 392 步，约为 SAC 的 1.95 倍，与零成功率共同说明策略在环境中无效徘徊。综合四项指标，算法对比支持选用 SAC-DepthMaxPool 作为下层主策略；PPO 在当前超参下不适用，留作后续调参，不纳入主结论。

2.3.3 单点导航能力评测

在联合评测之前，需验证最优 SAC 的单点“起点 → 随机目标”避障能力。评测为 500 次 episode：固定起点 (0, 0, 5)，目标按训练分布随机采样，每次独立飞行至单个目标点。结果见表 8。

表 8: 单点导航评测

评测次数	起点	到达成功率	碰撞率	成功时平均步数	成功时平均航程
500	(0, 0, 5)	95.2%	4.8%	228.40	54.38 m

500 次独立 episode 中，最优 SAC 到达成功率 95.2%（476/500），碰撞率 4.8%，与 20 万步对比实验终值（94% / 6%）基本一致，说明 10^5 步 checkpoint 在训练分布上仍保持可用泛化。成功回合平均 228.4 步、航程 54.38 m，对应 SimpleAvoid 中单段“起点 → 随机目标”的典型尺度。该结果从单点能力侧验证了联合评测所采用下层策略的可靠性：整链任务失败更可能来自序列段间衔接与累积障碍约束，而非单段导航本身完全不可用。

2.4 上下层联合评测

本课题选定经 10^5 步训练得到的最优 SAC (SAC-DepthMaxPool, SimpleAvoid, 深度 MaxPool 感知) 作为联合评测下层固定策略。联合评测从预生成的 500 组标准实例中抽取 100 组, 每组包含 Held-Karp 几何最优序列与指针网络 RL-Greedy 规划序列, 在相同模型与环境下逐组按序逐点导航, 统计整链完成率、碰撞率及成功时总航程。本阶段联合评测旨在检验路径质量 (上层 ratio/回路长度) 与任务成功率 (下层整链完成率) 之间的关系, 为中期之后引入障碍物惩罚 TSP 提供实证依据。

评测于 2026-06-10 完成, 汇总见表 9。在成功组上, 几何最优序列平均总航程 499.86 m ($n = 67$, $\sigma = 35.32$); RL-Greedy 序列 497.44 m ($n = 82$, $\sigma = 39.82$)。

表 9: 上下层联合评测 (100 组; 下层: 最优 SAC, 10^5 步)

规划序列	成功率	碰撞率	成功/总数	平均航程/m	标准差/m
Held-Karp 几何最优	67.0%	24.0%	67/100	499.86	35.32
RL-Greedy (指针网络)	82.0%	11.0%	82/100	497.44	39.82


注: 平均航程仅统计成功组; 失败组航程记为无效。

图 7 给出联合评测典型案例: 图 (a) 为上层 RL-Greedy 在无障碍度量空间中的闭合回路 (长度 401.60); 图 (b) 为下层 SAC 在 SimpleAvoid 含障环境中的实际飞行轨迹俯视图 (路程 581.22 m), 可见绕障与逐点访问; 图 (c) 为 AirSim 实时仿真界面, 展示深度感知与避障飞行过程。


在相同下层 SAC 策略下, Held-Karp 最优序列整链成功率 67% (67/100), RL-Greedy 为 82% (82/100), 差距 15 个百分点; 对应碰撞率 24% 与 11%。RL-Greedy 成功率高于几何最优序列, 但二者均明显低于单点导航评测的 95.2% (476/500), 分别低约 28 与 13 个百分点。这说明执行连续逐点任务会显著降低避障成功率: 段间过渡、累计偏航与障碍密集子段叠加, 使整链完成率远低于单段能力上限。

成功组平均总航程相近 (497.44 m 与 499.86 m, 仅差 0.5%), 说明上层几何序列规划与下层连续避障优化相互割裂。上层仅在无障碍度量空间中最短化回路长度, 下层才在含障环境中逐段执行; 两类序列的优劣主要体现在能否完成与碰撞中断 (碰撞率 24% vs 11%), 而非成功时飞得更远或更短。典型案例 (图 7) 也体现了这一错位: 上层回路长度 401.60, 下层实际飞行 581.22 m (约为几何长度的 1.45 倍), 差距来自绕障、偏航与段间过渡。

本课题面向无人机多目标作业。相较地面小车, 无人机一旦发生碰撞还存在炸机风险, 任务中断后的复飞、换机等成本更高。因此, 除安全约束外, 整链成功



(a) 上层规划路径



(b) 下层飞行轨迹



(c) AirSim 实时仿真

图 7: 联合评测可视化示例

率较路径几何最优更具工程优先级；在路径长度仍可接受的前提下，可优先保障任务完成，适度牺牲一部分路径最优性以换取成功率。上述结果指向中期之后的优化方向：在 TSP 训练中引入障碍物惩罚，使上层规划与下层可飞性对齐，在路径长度较优的基础上提升连续任务整链成功率。100 组样本的初步趋势需在扩展至 500 组后进一步检验。

2.5 阶段性小结

中期工作在上下层分别取得可量化进展，联合评测也暴露了规划与执行目标错位的问题。

上层，指针网络在 500 组 obstacle_map 实例上达到 $L/L_{opt} = 1.006$ （中位数 1.000，53.4% 实例最优），已优于 Christofides 等经典启发式。下层，SAC-DepthMaxPool 在算法与感知对比中表现最好（94% 成功率、6% 碰撞率），单点评测 95.2% 验证了单段避障的可用性。联合评测则显示，RL-Greedy 整链成功率（82%）虽高于几何最优（67%），但二者均明显低于单点 95.2%；连续逐点任务显著拉低避障成功率，成功组航程相近也表明上下层规划与执行相互割裂。鉴于无人机碰撞存在炸机风险且任务成本较高，整链成功率较路径几何最优更具优先级。中期之后的工作重心应转向 TSP 训练引入障碍物惩罚，将目标规模从 TSP20 扩展至 50 点及以上，并扩展至 500 组联合评测，在路径长度较优的基础上提升连续任务整链成功率。

3 目前存在的或预期可能出现的问题

当前主要问题集中在上下层目标不一致。上层优化无障碍欧氏距离，下层受障碍约束；单点导航成功率 95.2%，而联合评测中 Optimal 仅 67%、RL-Greedy 82%，连续任务显著拉低避障成功率，路径质量指标与任务成功率尚未对齐。

障碍物惩罚 TSP 尚未开展。上层仍假设无障碍度量空间，尚未在 TSP 训练/解码中引入障碍代价，这是中期之后论文主体的核心工作。

当前上层 TSP 训练与评测均固定为 $n = 20$ 个目标点（TSP20）。该规模便于 Held-Karp 求精确最优，但对农业巡检、工业运维等实际多目标作业的代表性仍不足；目标点数增至 50 乃至更多时，序列搜索空间与整链执行难度将显著上升，现有结论的外推性有待验证。后续计划在指针网络框架下开展 TSP50 及更大规模的训练与批量评测，并评估 ratio、训练收敛与联合评测可行性。

联合评测样本量仍有限，当前仅 100 组，需扩展至 500 组并量化 ratio 与联合成功率的协同或冲突规律。

算法对比实验中 PPO 成功率 0%，尚未收敛；后续可针对 PPO 调整专用超参数后重训，作为补充实验，但不纳入主线路。

4 后期学术研究或者实践工作的进度安排

表 10: 后期进度安排

时间	工作内容	预期成果
2026.06–07	联合评测扩展至 500 组	路径质量与成功率协同数据
2026.07–08	TSP 规模扩展至 50 点及以上	大规模训练收敛与 ratio 评测
2026.07–08	TSP 训练引入障碍物惩罚	含障代价模型与 ratio 对比
2026.08–09	障碍物惩罚 TSP 与联合评测闭环	整链成功率提升验证
2026.10–2027.01	论文撰写、补充实验	协同关系分析与讨论
2027.02–03	全文修改、预答辩	定稿

近期优先扩展联合评测至 500 组，将上层 TSP 从 20 点扩展至 50 点及以上并开展训练与评测，设计并实现 TSP 障碍物惩罚机制，完成路径质量与任务成功率的协同分析，并推进论文撰写与答辩准备。

- [1] Dewangan R K, Shukla A, Godfrey W W. Three dimensional path planning using Grey wolf optimizer for UAVs[J]. Applied Intelligence, 2019, 49(6): 2201-2217.
- [2] Bello I, Pham H, Le Q V, et al. Neural combinatorial optimization with reinforcement learning[C] //International Conference on Learning Representations (ICLR) Workshop. 2017.
- [3] Vinyals O, Fortunato M, Jaitly N. Pointer networks[C] // Advances in Neural Information Processing Systems. 2015: 2692-2700.
- [4] He L, Aouf N, Song B. Explainable deep reinforcement learning for UAV autonomous path planning[J/OL]. Aerospace Science and Technology, 2021, 118: 107052. <http://dx.doi.org/10.1016/j.ast.2021.107052>.
- [5] Liu Z, Cao Y, Chen J, et al. A hierarchical reinforcement learning algorithm based on attention mechanism for UAV autonomous navigation[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 24(11): 13309-13320.
- [6] Haarnoja T, Zhou A, Abbeel P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C] //International Conference on Machine Learning. [S.l.]: PMLR, 2018: 1861-1870.