

哈尔滨工业大学

硕士学位论文中期报告

题 目：基于深度强化学习的多目标无人机路径导航研究

院	(系)	计算学部
学	科	电子信息
导	师	李治军
研	究 生	王世豪
学	号	24S136052
中期报告日期		2026 年 6 月

研究生院制

目 录

1 学术研究或者实践工作进度情况	1
2 目前已完成的学术研究或者实践工作内容和取得的研究结果	1
2.1 两层系统总体设计	1
2.2 上层：基于指针网络的多目标 TSP 规划	2
2.2.1 指针网络 TSP 策略架构	2
2.3 下层：AirSim 环境上的 DRL 导航实验	5
2.3.1 SAC+DepthMaxPool 策略架构	7
2.3.2 实验：算法与感知对比	9
2.3.3 单点导航能力评测	10
2.4 上下层联合评测	11
2.5 阶段性小结	13
3 目前存在的或预期可能出现的问题	13
4 后期学术研究或者实践工作的进度安排	13

1 学术研究或者实践工作进度情况

本课题面向**农业巡检、工业运维**等多目标作业场景，采用“上层 TSP 序列规划 + 下层 AirSim 强化学习导航避障”的两层架构。上层将多目标点访问顺序抽象为 TSP，利用指针网络快速近似最优访问顺序；下层在 AirSim SimpleAvoid 场景中训练 SAC 等 DRL 策略，实现连续空间避障逐点飞行；上下层通过联合评测分析路径质量与任务成功率的协同关系。

研究路径分为两阶段。（1）**中期阶段（已完成）**：完成上层无障碍 TSP 训练与 500 实例评测、下层导航 benchmark 与单点能力验证、100 组初步联合评测，搭建“上层批量评测 → 联合评测”实验流水线。（2）**中期之后（论文主体）**：在 TSP 序列训练中引入障碍物惩罚，使上层规划与下层可飞性对齐，并扩展联合评测至 500 组，系统验证“路径质量—任务成功率”协同关系。

研究主要包括：（1）基于 NCO 框架的 TSP20 指针网络训练与 500 实例评测；（2）下层四种算法与感知配置对比（各 20 万训练步）；（3）100 组 Optimal vs RL-Greedy 初步联合评测；（4）为障碍物惩罚 TSP 与扩展联合评测预留流水线。

已完成主要内容如下。（1）**上层**：500 实例 TSP 评测完成，RL-Greedy 平均 $L/L_{\text{opt}} = 1.006$ ，并生成 ratio 曲线（图 4）及训练过程与单实例路径可视化（图 3）。（2）**下层算法对比**：SAC+DepthMaxPool 最终 rollout 成功率 94%（峰值 98%），TD3 75%，SAC+mlp 61%，PPO 未收敛（图 6）。（3）**联合评测**：以最优 SAC 为下层策略，100 组评测 Optimal 67%、RL-Greedy 82%（表 9），初步揭示几何最优序列在含障环境中任务成功率反而更低。（4）**单点导航**：最优 SAC 在训练分布下 500 次评测，成功率 95.2%（表 8）。（5）**工程化**：下层算法对比实验已自动化产出训练曲线与汇总数据。

对照开题进度，上层 TSP、下层导航 benchmark、初步联合评测均**按期完成**。障碍物惩罚 TSP 与扩展联合评测按研究路径安排在中期之后推进。联合评测采用经 10^5 步训练得到的**最优 SAC**（SAC+DepthMaxPool，SimpleAvoid 场景）作为下层固定策略，结果见表 9。

2 目前已完成的学术研究或者实践工作内容和取得的研究结果

2.1 两层系统总体设计

系统面向多目标巡检作业，分为上层序列规划与下层连续导航：上层输入 $N = 20$ 个二维目标点，用指针网络输出访问排列 π ；下层以 π 中各点为子目标，调用 SAC 在 AirSim 中依次避障飞行。实验数据流为：上层批量生成评测实例 → 构建标准测试集 → 上下层联合评测。中期之后将在上层 TSP 训练/解码中引入障碍物惩罚，使路径质量指标与下层任务成功率更好对齐。

图 1 从左至右展示三层信息流：多目标任务输入（航点集合 S 与含障环境）；中央为分层架构——上层 Pointer Network TSP 输出访问序列 π 及有序航点 $\pi(S)$ ，虚线框表示障碍物感知代价对序列规划的扩展输入；下层 SAC 策略在 AirSim 静态障碍环境中按子目标链逐段避障飞行；右侧为端到端执行轨迹。




图 1: 两层系统总体架构

2.2 上层：基于指针网络的多目标 TSP 规划

多目标几何路径建模为 TSP^[1]。上层采用 Bello 等人的 NCO 框架^[2]与 Vinyals 等人的指针机制^[3]，实现基于 Actor-Critic REINFORCE 的指针网络训练与多种解码策略。中期 500 实例评测采用与 SimpleAvoid 同尺度的障碍地图采样 ($n = 20$)；对照实验可切换为 NCO 原文的单位正方形均匀采样 ($[0, 1]^2$)。批量评测实验对 500 组实例分别计算 Christofides^[4]、2-opt、Held-Karp 最优及 RL-Greedy/Sampling/RL-AS 解码结果。

2.2.1 指针网络 TSP 策略架构

(1) 问题与输入。对称 TSP：给定 $n = 20$ 个二维城市坐标 $\mathbf{s}_i = (x_i, y_i)$ ，求访问排列 π 使闭合回路欧氏长度 $L(\pi)$ 最小。网络输入为 $(B, n, 2)$ 的 batch，无单独 depot 节点。

(2) **Encoder**。一维卷积层 $\text{Conv1d}(2 \rightarrow 128, k=1)$ 将各城市嵌入 128 维，再经 $\text{LSTM}(128 \rightarrow 128)$ 编码为节点序列 $\mathbf{h}_1, \dots, \mathbf{h}_n$ （表 1）。

(3) **PointerDecoder**。以 LSTM 末态 (h, c) 初始化 LSTM 单元，逐步解码 n 步：每步先用 **Glimpse** 注意力 ($w_{ref} \text{Conv1d} + w_q \text{Linear} + v \cdot \tanh$) 聚合未访问节点，再经指针层输出 $\text{logits} = C \cdot \tanh(\text{scores})$ ($C=10$)，对已访问城市施加 mask；训练时按 Categorical 采样，推理 Greedy 时 argmax 。推理阶段 scores 除以温度 $T=2.0$ 。

(4) **Critic 基线**。与 Encoder 同构的 embed+LSTM，接 3 步 *Glimpse process block* (NCO 原文设定) 与两层 FFN，输出标量 $b(s)$ 作为 REINFORCE 基线，降低梯度方差。

(5) **训练目标**。Actor 损失 $\mathbb{E}[(L(\pi) - b(s)) \log p(\pi)]$, Critic 损失 $\text{MSE}(b(s), L(\pi))$; Adam 优化, TSP20 下 batch=128、lr= 10^{-3} 、每 5000 步衰减 0.96、共 100k 步 (NCO 原文 250k)。梯度裁剪 $\|\nabla\|_2 \leq 1.0$ 。

(6) **推理解码**。RL-Greedy (逐步贪心, 默认上层输出); RL-Sampling (256 次随机采样取最短回路, balanced 预设); RL-AS (预训练权重 + 300 步实例级 Active Search, EMA 基线 $\alpha = 0.99$)。如图 2 所示, Encoder 编码输入序列后, Decoder 以 $\langle g \rangle$ 为起点, 通过 pointing 机制逐步选择未访问节点, mask 保证输出为有效排列 $\pi^{[3]}$; 本课题在此基础上按 NCO 框架^[2] 增加 Critic 基线与 TSP 回路长度训练目标。架构与训练/解码超参参见表 1、表 2。




图 2: 指针网络编码—解码机制示意

表 1: 指针网络 TSP 编码—解码—基线结构 (NCO §5.1)

层级	模块	说明
输入	$(B, n, 2)$ 城市坐标	障碍地图或单位正方形采样
Encoder	Conv1d + LSTM	$2 \rightarrow 128 \rightarrow 128$, 节点嵌入
Decoder	LSTMCell + Glimpse + Pointer	mask 已访问; logits = $\text{Ctanh}(\cdot)$
Critic	Encoder + 3×Glimpse + FFN	标量基线 $b(s)$
目标	回路长度 $L(\pi)$	对称 TSP 闭合回路欧氏长度

表 2: 指针网络 TSP 训练与解码超参 (TSP20 / 中期评测)

参数	训练	500 实例评测
城市数 n	20	20
batch / embed / hidden	128 / 128 / 128	—
学习率 / 衰减	10^{-3} , 5000 步 $\times 0.96$	—
训练步数	10^5 (NCO: 2.5×10^5)	—
C / 温度 T	10 / 2.0	推理用 T
Critic process 步数	3	—
RL-Greedy	—	逐步贪心解码
RL-Sampling	—	256 次采样取最短
RL-AS	—	300 步, $lr = 10^{-5}$, $\alpha = 0.99$

图 3 展示 REINFORCE 训练过程与单实例解码效果。(a) 为测试批平均回路长度随训练轮数的变化: 0–750 轮由约 900–1050 快速降至 550 附近, 750–7500 轮继续缓降至约 440–450, 7500 轮后进入平台期并在 2 万轮附近稳定在 420–430, 表明指针网络在 `obstacle_map` 分布上已习得有效的序列构造策略; 曲线全程存在高频抖动, 来自 REINFORCE 采样式梯度估计的固有方差, 整体无发散或性能回退。该曲线与 500 实例评测中 RL-Greedy 均值 408.18 的量级一致——完整 10^5 步训练后几何质量将进一步收敛至表 3 所示水平。(b) 为 `obstacle_map` 尺度下单组 20 城市实例的 RL-Greedy 闭合回路: 红色折线依次连接各航点并回到起点, 形成有效 Hamiltonian 环; 多数相邻段遵循“就近连接”的局部几何直觉, 左中部与右缘可见少量自交叉或折返, 对应尚未达到 Held-Karp 最优的局部冗余, 与全量评测均值 ratio 1.006、53.4% 实例达最优的统计相符。该访问序经转换为逐点目标序列后, 即作为下层 SAC 的子目标输入。

500 实例汇总见表 3、表 4 与图 4。

结果分析 从绝对回路长度看, RL-Greedy 均值 408.18 已低于 Christofides (421.27) 与 2-opt (452.53), 并逼近 Held-Karp 最优 (405.65); 标准差 26.26 与最优解 25.27 同量级, 说明 learned 策略在 `obstacle_map` 实例上不仅均值优, 离散程度也与精确最优相当。相对最优比率进一步揭示这一优势: RL-Greedy 均值 $L/L_{\text{opt}} = 1.006$, 中位数为 1.000——即半数实例已达最优; 267/500 (53.4%) 与最优等长, 434/500 (86.8%) 短于 Christofides, 而 Christofides 仅 49/500 优于 RL-Greedy, 表明在本文




图 3: 指针网络 TSP 训练过程与单实例路径可视化 (obstacle_map, $n = 20$)

地图分布下经典近似算法并不占优。

图 4 的排序曲线呈现清晰分层：随机初始序（均值 ratio 3.31）与启发式（Christofides 1.04、2-opt 1.12）位于上方，RL 系列（Greedy/Sampling/RL-AS）紧贴最优曲线下方。解码策略方面，256 次采样的 RL-Sampling 将均值 ratio 降至 1.001，446/500 达最优，相对 Greedy 的 267/500 有 179 例提升，但均值差距仅 0.005，说明 Greedy 已接近采样解码的收益上限；RL-AS（300 步）与 Sampling 均值接近（1.0015 vs 1.0010），实例级微调带来的边际收益有限。综上，上层指针网络在中期设定下已具备可用的序列规划能力，后续瓶颈不在几何 ratio，而在与下层可飞性的对齐。

表 3: 上层 TSP 各方法平均回路长度（500 实例）

方法	均值	标准差	最小值	最大值	实例数
初始随机序	1337.77	142.59	991.69	1776.93	500
Christofides	421.27	33.20	343.81	550.73	500
2-opt	452.53	42.19	366.71	599.49	500
RL-Greedy	408.18	26.26	343.81	501.42	500
RL-Sampling	406.05	25.53	341.42	501.02	500
RL-AS	406.30	25.65	341.42	501.42	500
Optimal	405.65	25.27	341.42	501.02	500

2.3 下层：AirSim 环境上的 DRL 导航实验

参考 He 等人^[5] 的 AirSim 深度强化学习导航框架与 Liu 等人的层次 DRL 导航^[6]，本人在 Gym 接口下封装 SimpleAvoid 多旋翼仿真环境，采用 SAC^[7] 为主算法（原文为 TD3），奖励采用综合塑形函数。下层主策略为 **SAC+DepthMaxPool**（深度

表 4: 上层 TSP 相对最优比率及配对统计 (500 实例)

方法 / 统计项	数值	说明
RL-Greedy ratio 均值	1.006	本文默认上层输出
RL-Sampling ratio 均值	1.001	best-of-256
RL-Greedy 达到最优	267/500	与 Held-Karp 等长
RL-Greedy 短于 Christofides	434/500	配对比较




图 4: TSP 相对最优比率曲线 (500 实例)

MaxPool 编码器)：在 Stable-Baselines3 策略框架上挂载自定义 DepthMaxPool 特征提取器，按统一超参数配置进行训练。

2.3.1 SAC+DepthMaxPool 策略架构

(1) 环境接口。感知采用深度图模式：AirSim 深度传感器输出经裁剪、缩放为 60×90 深度图（有效距离 15 m，近障碍高亮），与 2 维状态特征共同构成双通道观测 $\mathbf{o} \in \mathbb{R}^{60 \times 90 \times 2}$ 。状态特征嵌入第二通道首行，2D 导航下为归一化水平距离与相对偏航角；动作 $\mathbf{a} = (v_{xy}, \dot{\psi})$ ，分别为水平速度与偏航角速度 ($v_{xy} \in [0.5, 5]$ m/s, $\dot{\psi} \in [-30^\circ, 30^\circ]/s$)。动力学采用简化多旋翼模型 ($dt = 0.1$ s)，奖励含距离塑形与障碍/姿态惩罚。

(2) **DepthMaxPool 特征提取**。DepthMaxPool 对深度通道做 16×20 区域最大池化（无卷积）： 60×90 深度图降采样为 $3 \times 4 = 12$ 维区域最大深度；再从第二通道读取 2 维状态，拼接为 14 维向量供后续 MLP 使用（表 5）。

(3) **SAC 策略网络**。DepthMaxPool 作为 Actor 与 Twin Critic 的共享特征提取器。Actor 经 MLP [64, 32, 16] (tanh) 输出 Squashed Gaussian 分布；Critic 为双 Q 网络。Off-policy 训练采用经验回放 (buffer 50000, batch 512)，每 100 步采集后更新 100 次梯度；探索阶段附加 $\sigma = 0.15$ 高斯动作噪声。图 5 概括感知—DepthMaxPool—SAC 三层数据流：深度图经区域 MaxPool 压缩为 12 维障碍特征，与 2 维状态拼接后供 Actor/Critic 共享；算法对比实验中该配置 rollout 成功率 94%。细节见表 5、表 6。




图 5: SAC+DepthMaxPool 策略架构

表 5: SAC+DepthMaxPool 观测—特征—策略结构

层级	模块	说明
感知	AirSim 深度传感器	resize 60×90 , 映射 $[0, 15] \text{ m} \rightarrow [0, 255]$
观测	双通道 $(H, W, 2)$	通道 0: 深度; 通道 1 第 0 行: 状态
特征	DepthMaxPool	MaxPool $\rightarrow$ 12 维 + 状态 2 维 = 14 维
Actor	MLP[64, 32, 16]+Squash	输出 (v_{xy}, ψ)
Critic	Twin Q, 共享特征	Q_1, Q_2 : 特征与动作拼接后 MLP

表 6: SAC+DepthMaxPool 训练超参（对比实验 / 最优模型）

参数	对比实验	最优 SAC
训练步数	2×10^5	10^5
学习率 / γ	$10^{-3} / 0.99$	同左
buffer / batch	50000 / 512	同左
采集间隔 / 梯度更新	100 步 / 100 次	同左
网络结构	[64, 32, 16]	同左
动作噪声 σ	0.15	同左
accept / crash 半径	2 m / 2 m	同左


相较 SAC+mlp（5 维手工向量特征），DepthMaxPool 保留完整深度图的空间结构，对比实验中最终成功率 94% vs 61%。本课题选定 SAC+DepthMaxPool 作为下层主策略及联合评测固定执行器。

2.3.2 实验：算法与感知对比


对比 SAC、TD3、PPO 及 SAC+mlp（向量感知消融）四组配置，汇总见表 7，训练过程 rollout 指标曲线见图 6。

表 7: 下层导航算法对比（SimpleAvoid，各 20 万步，rollout 指标）


配置	算法	最终成功率	峰值成功率	最终平均奖励	撞毁率	平均步数
SAC+DepthMaxPool	SAC	94%	98%	+9.55	6%	201
TD3+DepthMaxPool	TD3	75%	84%	+3.72	24%	164
SAC+mlp	SAC	61%	74%	-13.95	37%	227
PPO+DepthMaxPool	PPO	0%	0%	-244.24	5%	392




(a) 成功率



(b) 碰撞率



(c) 平均回合奖励



(d) 平均回合步数

图 6: 四种配置训练 rollout 指标曲线

结果分析 四组 rollout 曲线在四项指标上形成稳定排序，SAC+DepthMaxPool 综合最优，且各指标之间逻辑自洽。

(a) **成功率与收敛速度。**SAC 曲线在中期约 4.4 万步首次超过 75%，7.2 万步超过 90%，20 万步终值 94%（峰值 98%）；TD3 直至 14.7 万步才达到 75%，全程未突破 90%。在共享 DepthMaxPool 感知的前提下，SAC 比 TD3 提前约 10 万步进入可用区间，终值成功率高出 19 个百分点，说明 off-policy 双 Q 结构与熵正则在本环境中更利于样本效率。SAC+mlp 终值 61%（峰值 74%），全程未达 75%，与 SAC+DepthMaxPool 形成 33 个百分点的感知消融差距，表明 12 维区域深度特征对障碍空间结构的保留是性能跃升的关键。PPO 成功率恒为 0%，策略未习得有效到达行为。

(b) **碰撞率。**碰撞率与成功率呈显著负相关：SAC 终值 6%，TD3 24%，SAC+mlp 37%。TD3 成功率低于 SAC 但碰撞率却为其 4 倍，说明 TD3 在部分回合中以撞障或失败终止，而非稳定到达。PPO 碰撞率 5% 看似较低，但结合 0% 成功率与 392 步的平均回合长度，更可能以超时或边界条件结束回合，而非安全到达。

(c) **平均奖励。**SAC 在约 4.9 万步首次转正，终值 +9.55（训练期峰值 +13.40）；TD3 约 13.8 万步才转正，终值 +3.72。SAC+mlp 与 PPO 终值分别为 -13.95 与 -244.24，全训练期均值亦为负（-30.5 与 -226.8），反映策略长期受距离塑形与障碍惩罚压制。奖励曲线与成功率曲线在 SAC 上同步上升，可作为训练监控的有效代理指标。

(d) **平均步数与效率。**SAC 终值约 201 步/回合，TD3 约 164 步——TD3 步数更短但成功率更低，说明其回合往往更早以失败结束；PPO 约 392 步，约为 SAC 的 1.95 倍，与零成功率共同说明策略在环境中无效徘徊。综合四项指标，算法对比支持“SAC + DepthMaxPool”作为下层主策略；PPO 在当前超参下不适用，留作后续调参，不纳入主结论。

2.3.3 单点导航能力评测

在联合评测之前，需验证最优 SAC 的单点“起点 → 随机目标”避障能力。评测于 2026-06-16 完成（500 次 episode）：固定起点 (0, 0, 5)，目标按训练分布随机采样，每次独立飞行至单个目标点。结果见表 8。

表 8: 单点导航评测

评测次数	起点	到达成功率	碰撞率	成功时平均步数	成功时平均航程
500	(0, 0, 5)	95.2%	4.8%	228.40	54.38 m

结果分析 500 次独立 episode 中，最优 SAC 到达成功率 95.2%（476/500），碰撞率 4.8%，与 20 万步对比实验终值（94% / 6%）基本一致，说明 10^5 步 checkpoint 在训

练分布上仍保持可用泛化。成功回合平均 228.4 步、航程 54.38 m，对应 SimpleAvoid 中单段“起点 → 随机目标”的典型尺度。该结果从单点能力侧验证了联合评测所采用下层策略的可靠性：整链任务失败更可能来自序列段间衔接与累积障碍约束，而非单段导航本身完全不可用。

2.4 上下层联合评测

本课题选定经 10^5 步训练得到的最优 SAC (SAC+DepthMaxPool, SimpleAvoid, 深度 MaxPool 感知) 作为联合评测下层固定策略。联合评测从预生成的 500 组标准实例中抽取 100 组，每组包含 Held-Karp 几何最优序列与指针网络 RL-Greedy 规划序列，在相同模型与环境下逐组按序逐点导航，统计整链完成率、碰撞率及成功时总航程。本阶段联合评测旨在验证路径质量（上层 **ratio**/回路长度）与任务成功率（下层整链完成率）之间的协同关系，为中期之后引入障碍物惩罚 TSP 提供实证依据。

评测于 2026-06-10 完成，汇总见表 9。在成功组上，几何最优序列平均总航程 499.86 m ($n = 67$, $\sigma = 35.32$)；RL-Greedy 序列 497.44 m ($n = 82$, $\sigma = 39.82$)。

表 9: 上下层联合评测（100 组；下层：最优 SAC， 10^5 步）


规划序列	成功率	碰撞率	成功/总数	平均航程/m	标准差/m
Held-Karp 几何最优	67.0%	24.0%	67/100	499.86	35.32
RL-Greedy（指针网络）	82.0%	11.0%	82/100	497.44	39.82

注：平均航程仅统计成功组；失败组航程记为无效。


图 7 给出联合评测典型案例：(a) 上层 RL-Greedy 在无障碍度量空间中的闭合回路（长度 401.60）；(b) 下层 SAC 在 SimpleAvoid 含障环境中的实际飞行轨迹俯视图（路程 581.22 m），可见绕障与逐点访问；(c) AirSim 实时仿真界面，展示深度感知与避障飞行过程。

结果分析 联合评测的核心发现是：上层几何最优序列并不保证下层整链成功。Held-Karp 最优序列成功率 67% (67/100)，低于 RL-Greedy 的 82% (82/100)，差距 15 个百分点；对应碰撞率 24% vs 11%，最优序列的撞障概率约为 RL-Greedy 的 2.2 倍。值得注意的是，成功组平均总航程差异很小 (499.86 m vs 497.44 m，仅差 0.5%)，说明两类序列的优劣主要体现在“能否完成”而非“飞得更短”——RL-Greedy 多出的 15 次成功并非以显著增加航程为代价。

从机制上理解，Held-Karp 在无障欧氏度量下最小化回路长度，可能将相邻航点按几何顺序连接，使部分子段穿越障碍密集区；RL-Greedy 虽 ratio 仅 1.006，



(a) 上层规划路径



(b) 下层飞行轨迹



(c) AirSim 实时仿真

图 7: 联合评测可视化示例

其访问顺序在统计上避开了对下层 SAC 更“困难”的段序组合。典型案例（图 7）进一步揭示执行层代价：上层回路长度 401.60，下层实际飞行 581.22 m（约为几何长度的 1.45 倍），差距来自绕障、偏航与段间过渡，表明仅优化上层无障碍 TSP 无法刻画真实飞行代价。上述结果定量支持中期之后引入障碍物感知 TSP 的必要性；100 组样本的初步趋势需在扩展至 500 组后检验统计稳健性。

2.5 阶段性小结

中期工作在上下层分别取得可量化进展，且联合评测暴露了规划—执行目标错位这一核心问题。

上层，指针网络在 500 组 obstacle_map 实例上达到 $L/L_{\text{opt}} = 1.006$ （中位数 1.000，53.4% 实例最优），已优于 Christofides 等经典启发式；下层，SAC+DepthMaxPool 在算法与感知对比中全面领先（94% 成功率、6% 碰撞率），单点评测 95.2% 验证策略可用。然而联合评测表明：几何最优序列整链成功率（67%）低于 RL-Greedy（82%），且成功组航程几乎相同——路径 **ratio** 优势不能单调转化为任务成功。中期之后的工作重心应转向障碍物感知 TSP 与 500 组扩展联合评测，以建立路径质量与任务成功率之间的可解释关联。

3 目前存在的或预期可能出现的问题

（1）上下层目标不一致：上层优化无障碍欧氏距离，下层受障碍约束；Optimal 联合成功率（67%）低于 RL-Greedy（82%），说明路径质量指标与任务成功率尚未对齐。

（2）障碍物惩罚 TSP 尚未开展：上层仍假设无障碍度量空间，尚未在 TSP 训练/解码中引入障碍代价，这是中期之后论文主体的核心工作。

（3）联合评测样本量有限：当前仅 100 组，需扩展至 500 组并量化 ratio 与联合成功率的协同/冲突规律。

（4）PPO 未收敛：算法对比实验中 PPO 成功率 0%，需针对 PPO 调整专用超参数后重训（非主线路，可选补充）。

4 后期学术研究或者实践工作的进度安排

近期优先：扩展联合评测至 500 组；设计并实现 TSP 障碍物惩罚机制；完成“路径质量—任务成功率”协同分析；推进论文撰写与答辩准备。

- [1] Dewangan R K, Shukla A, Godfrey W W. Three dimensional path planning using Grey wolf optimizer for UAVs[J]. Applied Intelligence, 2019, 49(6): 2201-2217.
- [2] Bello I, Pham H, Le Q V, et al. Neural combinatorial optimization with reinforcement learning[C] // International Conference on Learning Representations (ICLR) Workshop. 2017.

表 10: 后期进度安排 (2026 年 6 月–2027 年 3 月)

时间	工作内容	预期成果
2026.06–07	联合评测扩展至 500 组	路径质量—成功率协同数据
2026.07–08	TSP 训练引入障碍物惩罚	含障代价模型 + ratio 对比
2026.08–09	障碍物惩罚 TSP + 联合评测闭环	整链成功率提升验证
2026.10–11	系统架构图与论文第 3–5 章撰写	图 1 + 方法实验
2026.12–2027.01	论文修改、补充实验	协同关系分析与讨论
2027.02–03	全文修改、预答辩	定稿

- [3] Vinyals O, Fortunato M, Jaitly N. Pointer networks[C] // Advances in Neural Information Processing Systems. 2015: 2692-2700.
- [4] Christofides N. Worst-case analysis of a new heuristic for the travelling salesman problem[J]. Management Sciences Research Report, 1976, 388.
- [5] He L, Aouf N, Song B. Explainable deep reinforcement learning for UAV autonomous path planning[J/OL]. Aerospace Science and Technology, 2021, 118: 107052. <http://dx.doi.org/10.1016/j.ast.2021.107052>.
- [6] Liu Z, Cao Y, Chen J, et al. A hierarchical reinforcement learning algorithm based on attention mechanism for UAV autonomous navigation[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 24(11): 13309-13320.
- [7] Haarnoja T, Zhou A, Abbeel P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C] // International Conference on Machine Learning. [S.l.]: PMLR, 2018: 1861-1870.